

Semana 15

CÁLCULO NUMÉRICO

Prof. Maria Clara Schuwartz Ferreira
mclarascferreira@gmail.com

Conteúdo da Semana 15

1. Ajuste de curvas
2. O método dos mínimos quadrados
3. Ajuste de uma reta
4. Ajuste linear geral
5. Ajuste com parâmetros não lineares


Ajuste de curvas

- Interpolação VS Extrapolação

- Interpolação: uma forma de se trabalhar com uma função definida por uma tabela de valores.

A interpolação pode não ser aconselhável quando:

- É preciso obter um valor em algum ponto fora do intervalo de tabelamento (extrapolação).
- Os valores tabelados são resultado de experimentos físicos (podendo conter erros inerentes que, em geral, não são previsíveis).




Ajuste de curvas


- Dado um conjunto de pontos $(x_1, y_1), \dots, (x_n, y_n)$, queremos encontrar a melhor curva $f(x)$ que se ajuste a este conjunto de dados.



- Diagrama de dispersão e ajuste de curva:



$$y \stackrel{?}{=} ax + b$$



$$y \stackrel{?}{=} a \sin(px) + b \cos(px) + c$$


Conteúdo da Semana 15

1. Ajuste de curvas
2. O método dos mínimos quadrados
3. Ajuste de uma reta
4. Ajuste linear geral
5. Ajuste com parâmetros não lineares

O método dos mínimos quadrados

- É necessário chegar a um consenso quanto ao melhor ajuste $f(x)$.
- Apenas somar os desvios $d_k = f(x_k) - y_k$

Minimizar $\sum d_k$




$$d_1 = f(x_1) - y_1 = y_1 - y_1 = 0$$

$$d_2 = f(x_2) - y_2 = y_2 - y_2 = 0$$

$$d_1 = f(x_1) - y_1 = y_2 - y_1 \Rightarrow d_1 + d_2 = 0$$

$$d_2 = f(x_2) - y_2 = y_1 - y_2$$



- Somar os valores absolutos dos desvios $d_k \rightarrow$ Minimizar $\sum |d_k|$
- Somar os quadrados dos desvios

Minimizar $R = \sum d_k^2$

← Método mínimos quadrados

R é chamado de resíduo.

Conteúdo da Semana 15

1. Ajuste de curvas
2. O método dos mínimos quadrados
3. Ajuste de uma reta
4. Ajuste linear geral
5. Ajuste com parâmetros não lineares



Ajuste de uma reta


- Queremos determinar a reta de mínimos quadrados $f(x) = a_1 + a_2x$ que aproxima, ou ajusta, o conjunto de pontos $(x_1, y_1), \dots, (x_n, y_n)$

→ a_1 e a_2 são incógnitas a serem determinadas de maneira a minimizar $R = \sum d_k^2$

$$d_k = f(x_k) - y_k \quad \Rightarrow \quad d_k = a_1 + a_2x_k - y_k$$

$$\Rightarrow R(a_1, a_2) = \sum (a_1 + a_2x_k - y_k)^2$$

→ Função nas variáveis a_1 e a_2 .



O mínimo ocorre quando $\frac{\partial R}{\partial a_1} = \frac{\partial R}{\partial a_2} = 0$

$$\Rightarrow \frac{\partial R}{\partial a_1} = \sum 2(a_1 + a_2x_k - y_k) = 0$$

$$\Rightarrow \frac{\partial R}{\partial a_2} = \sum 2x_k(a_1 + a_2x_k - y_k) = 0$$

$$\rightarrow \begin{cases} a_1 \sum 1 + a_2 \sum x_k = \sum y_k \\ a_1 \sum x_k + a_2 \sum x_k^2 = \sum x_k y_k \end{cases}$$



Ajuste de uma reta

- Forma matricial do sistema:

$$\underbrace{\begin{bmatrix} n & \sum x_k \\ \sum x_k & \sum x_k^2 \end{bmatrix}}_M \underbrace{\begin{bmatrix} a_1 \\ a_2 \end{bmatrix}}_w = \underbrace{\begin{bmatrix} \sum y_k \\ \sum x_k y_k \end{bmatrix}}_w \Rightarrow$$

$$a_1 = \frac{\sum x_k^2 \sum y_k - \sum x_k \sum x_k y_k}{n \sum x_k^2 - (\sum x_k)^2}$$

$$a_2 = \frac{n \sum x_k y_k - \sum x_k \sum y_k}{n \sum x_k^2 - (\sum x_k)^2}$$

$$Ma = w$$

- **Obs:** Dado $V = \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix}$, $M = V^T V$ e $w = V^T y$


$$Ma = w \Rightarrow V^T V a = V^T y \Rightarrow a = (V^T V)^{-1} V^T y$$

Ajuste de uma reta

- **Exemplo:** A dureza (HB) para aços comuns recozidos varia com a quantidade de perlita (um tipo de estrutura cristalina do aço) presente:

% de Perlita	25	50	75	100
Dureza (HB)	120	138	190	240

- a) Obtenha um modelo matemático para descrever os dados medidos
- b) Qual a dureza do material com 90% de Perlita?



a)

Observamos visualmente um comportamento linear da dureza D em relação a porcentagem de perlita P

Forma do modelo: $y = a_1 + a_2x$

onde y é a dureza e x é a porcentagem de perlita.


Ajuste de uma reta

					Σ
x (% de Perlita)	25	50	75	100	250
y (Dureza)	120	138	190	240	688
x^2	625	2500	5625	10000	18750
xy	3000	6900	14250	24000	48150

$$a_1 = \frac{\Sigma x^2 \Sigma y - \Sigma x \Sigma xy}{n \Sigma x^2 - (\Sigma x)^2} = \frac{18750(688) - 250 \cdot (48150)}{4(18750) - (250)^2} = 69$$

$$a_2 = \frac{n \Sigma xy - \Sigma x \Sigma y}{n \Sigma x^2 - (\Sigma x)^2} = \frac{4(48150) - 250 \cdot (688)}{4(18750) - (250)^2} = 1,648$$

$$y = 69 + 1,648x$$



b) Substituindo $P = 90$ em (*) temos

$$D = 69 + 1,648 \cdot 90 = 217,32$$

Conteúdo da Semana 15

1. Ajuste de curvas
2. O método dos mínimos quadrados
3. Ajuste de uma reta
4. Ajuste linear geral
5. Ajuste com parâmetros não lineares



Ajuste linear geral

- Dado o conjunto $(x_1, y_1), \dots, (x_n, y_n)$ e uma família de funções $\{f_1(x), f_2(x), \dots, f_m(x)\}$, queremos determinar a função $f(x) = a_1 f_1(x) + \dots + a_m f_m(x)$ que minimiza o resíduo $R(a_1, \dots, a_m) = \sum (f(x_k) - y_k)^2$.
- **Obs:** No caso de ajuste de uma reta que fizemos anteriormente a família de funções era $\{1, x\}$.

O mínimo para o resíduo ocorre quando $\frac{\partial R}{\partial a_k} = 0$ para $k = 1, \dots, m$

$$\Rightarrow \frac{\partial R}{\partial a_1} = \sum 2f_1(x_k)(a_1 f_1(x_k) + \dots + a_m f_m(x_k) - y_k) = 0$$

\vdots

$$\Rightarrow \frac{\partial R}{\partial a_m} = \sum 2f_m(x_k)(a_1 f_1(x_k) + \dots + a_m f_m(x_k) - y_k) = 0$$



Ajuste linear geral

$$\underbrace{\begin{bmatrix} \sum (f_1(x_k))^2 & \cdots & \sum f_1(x_k)f_m(x_k) \\ \vdots & \ddots & \vdots \\ \sum f_1(x_k)f_m(x_k) & \cdots & \sum (f_m(x_k))^2 \end{bmatrix}}_M \underbrace{\begin{bmatrix} a_1 \\ \vdots \\ a_m \end{bmatrix}}_a = \underbrace{\begin{bmatrix} \sum f_1(x_k)y_k \\ \vdots \\ \sum f_m(x_k)y_k \end{bmatrix}}_w$$

$$Ma = w$$

- **Obs1:** Dado $V = \begin{bmatrix} f_1(x_1) & \cdots & f_m(x_1) \\ f_1(x_2) & \cdots & f_m(x_2) \\ \vdots & \ddots & \vdots \\ f_1(x_n) & \cdots & f_m(x_n) \end{bmatrix}$, $M = V^T V$ e $w = V^T y$


$$Ma = w \Rightarrow V^T V a = V^T y \Rightarrow a = (V^T V)^{-1} V^T y$$

- **Obs2:** Interpolação polinomial é o caso particular do ajuste linear para funções polinomiais $\{f_1(x), f_2(x), f_3(x), \dots\} = \{1, x, x^2, \dots\}$

Ajuste linear geral

- Exemplo:** Encontre a função $f(x) = a_1 \sin(\pi x) + a_2 \cos(\pi x)$ que melhor se ajusta pelo critério dos mínimos quadrados aos seguintes pontos dados

x	0,00	0,25	0,50	0,75	1,00
y	-153	64	242	284	175



$$y = 244,03658 \sin(\pi x) - 161,18783 \cos(\pi x)$$

$$f_1(x) = \sin(\pi x) \text{ e } f_2(x) = \cos(\pi x) \quad a = \begin{bmatrix} a_1 \\ a_2 \end{bmatrix} = ?$$

$$V = \begin{bmatrix} \sin(0 \cdot \pi) & \cos(0 \cdot \pi) \\ \sin(0,25\pi) & \cos(0,25\pi) \\ \sin(0,5\pi) & \cos(0,5\pi) \\ \sin(0,75\pi) & \cos(0,75\pi) \\ \sin(\pi) & \cos(\pi) \end{bmatrix}$$

$$a = (V^T V)^{-1} V^T y$$

$$a = \begin{bmatrix} 244,03658 \\ -161,18783 \end{bmatrix}$$

Conteúdo da Semana 15

1. Ajuste de curvas
2. O método dos mínimos quadrados
3. Ajuste de uma reta
4. Ajuste linear geral
5. Ajuste com parâmetros não lineares

Ajuste com parâmetros não lineares

- Em alguns casos, a família de funções escolhidas pode ser não linear nos parâmetros, isto é, f não é da forma $f(x) = a_1 f_1(x) + \dots + a_m f_m(x)$

⇒ Resolver um sistema **não linear**

- Nestes casos é precisa efetuar uma “linearização” através de **transformações** convenientes.
- **Exemplo:** Encontre uma curva da forma $y = a_1 e^{a_2 x}$ que melhor ajusta os pontos $(1, 2)$, $(2, 3)$ e $(3, 5)$.

$$f(x) = \ln y = \underbrace{\ln a_1}_{b_1} + \underbrace{a_2 x}_{b_2}$$

⇒ Resolvemos o ajuste para $f(x) = \ln y = b_1 + b_2 x$ com os pontos:

$(1, \ln 2)$, $(2, \ln 3)$ e $(3, \ln 5)$.



Ajuste com parâmetros não lineares

Modelo para $y = a_1 e^{a_2 x}$ com pontos (1, 2), (2, 3) e (3, 5).



Modelo para $f(x) = \ln y = b_1 + b_2 x$ com pontos (1, $\ln 2$), (2, $\ln 3$) e (3, $\ln 5$).


$\Rightarrow b_1 = 0,217442$ e $b_2 = 0,458145$

$\Rightarrow a_1 = 1,242890$ e $a_2 = 0,458145$

Obs: Estamos minimizando $\sum (\ln f(x_k) - \ln y_k)^2$
em vez de $\sum (f(x_k) - y_k)^2$

\Rightarrow Os coeficientes obtidos a partir dessa linearização são aproximados

Se resolvêssemos o sistema não linear a solução seria $a_1 = 1,19789$ e $a_2 = 0,47438$.



Ajuste com parâmetros não lineares

- Tabela com algumas curvas e transformações para linearizar o ajuste:

Curva	Transformação	Problema linearizado
$y = a_1 e^{a_2 x}$	$f(x) = \ln y$	$f(x) = \ln a_1 + a_2 x$
$y = a_1 x^{a_2}$	$f(x) = \ln y$	$f(x) = \ln a_1 + a_2 \ln x$
$y = \frac{a_1}{a_2 + x}$	$f(x) = \frac{1}{y}$	$f(x) = \frac{a_2}{a_1} + \frac{1}{a_1} x$
$y = \sqrt{a_1 + a_2 x}$	$f(x) = y^2$	$f(x) = a_1 + a_2 x$

Semana 15 - Fim

CÁLCULO NUMÉRICO

Prof. Maria Clara Schuwartz Ferreira
mclarascferreira@gmail.com